

Coletando dados financeiros

Lucca Simeoni Pavan

João Carlos de Carvalho

7 de novembro de 2016

Sumário

1	Coletando dados usando o pacote <code>GetHFData</code>	1
2	Coletando dados usando <code>quantmod</code>	5
3	Organizando a base de dados	6
3.1	Plotando os retornos dos ativos	7
4	Propriedades da distribuição dos retornos	8
	Referências	9

```
knitr::opts_chunk$set(echo = TRUE, cache = TRUE, warning = FALSE, message = FALSE,
  error = FALSE, tidy = TRUE, tidy.opts = list(width.cutoff = 70))
```

1 Coletando dados usando o pacote `GetHFData`

Os dados podem ser coletados usando o pacote `GetHFData` desenvolvido por Perlin (2016). Para maiores detalhes sobre o pacote veja também Perlin and Ramos (2016). Primeiramente baixaremos os *layouts* da base de dados usando o comando `gthf_download_file`.

```
library(GetHFData)
layout_negocios <- "ftp://ftp.bmf.com.br/MarketData/NEG_LAYOUT_portuguese.txt"
ghfd_download_file(layout_negocios, out.file = "layout_negocios")
```

```
## Attempt 1 - File exists, skipping dl
```

```
layout_oferta_compra <- "ftp://ftp.bmf.com.br/MarketData/OFER_CPA_LAYOUT_portuguese.txt"
ghfd_download_file(layout_oferta_compra, out.file = "layout_oferta_compra")
```

```
## Attempt 1 - File exists, skipping dl
```

```
layout_oferta_venda <- "ftp://ftp.bmf.com.br/MarketData/OFER_VDA_LAYOUT_portuguese.txt"
ghfd_download_file(layout_oferta_venda, out.file = "layout_oferta_venda")
```

```
## Attempt 1 - File exists, skipping dl
```

Attempt 1 e TRUE significam que o download na primeira tentativa foi realizado com sucesso. A mensagem File exists, skipping dl aparece quando o comando for acionado pela segunda vez e portanto o documento já foi baixado. Os arquivos de *layout* podem ser abertos pelo bloco de notas.

O comando `ghfd_get_ftp_contents` acessa o ftp da Bovespa e retorna um vetor com todos os arquivos relacionados à negócios (todos os outros são ignorados).

```
library("GetHFDData")
contents_equity <- ghfd_get_ftp_contents(type.market = "equity")
```

```
##
## Reading ftp contents for equity (attempt = 1|10)
```

```
contents_options <- ghfd_get_ftp_contents(type.market = "options")
```

```
##
## Reading ftp contents for options (attempt = 1|10)
```

```
contents_bmf <- ghfd_get_ftp_contents(type.market = "BMF")
```

```
##
## Reading ftp contents for BMF (attempt = 1|10)
```

Usando os comandos `head` e `tail` podemos ver os 6 primeiros e 6 últimos elementos dos arquivos baixados anteriormente.

```
head(contents_equity)
```

```
##           files      dates
## 1 NEG_20141103.zip 2014-11-03
## 2 NEG_20141104.zip 2014-11-04
## 3 NEG_20141105.zip 2014-11-05
## 4 NEG_20141106.zip 2014-11-06
## 5 NEG_20141107.zip 2014-11-07
## 6 NEG_20141110.zip 2014-11-10
##
##                                     link
## 1 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141103.zip
## 2 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141104.zip
## 3 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141105.zip
## 4 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141106.zip
## 5 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141107.zip
## 6 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20141110.zip
```

```
tail(contents_equity)
```

```
##           files      dates
## 462 NEG_20160823.zip 2016-08-23
## 463 NEG_20160824.zip 2016-08-24
## 464 NEG_20160825.zip 2016-08-25
## 465 NEG_20160826.zip 2016-08-26
## 466 NEG_20160829.zip 2016-08-29
```

```
## 467 NEG_20160830.zip 2016-08-30
##
## link
## 462 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160823.zip
## 463 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160824.zip
## 464 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160825.zip
## 465 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160826.zip
## 466 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160829.zip
## 467 ftp://ftp.bmf.com.br/marketdata/Bovespa-Vista/NEG_20160830.zip
```

O primeiro dia disponível para o mercado de ações (*equity*) é 2014-11-03 e o último é 2016-08-30. Os arquivos .zip armazenam dados das transações diárias e obviamente somente de segunda à sexta-feira.

Para sabermos os *tickers* (nomes dos ativos transacionados, ex. para o mercado de ações PETR4, é um *ticker* para ações da PETROBRAS) podemos usar o comando `ghfd_get_available_tickers_from_file` que obtém os *tickers* disponíveis de um arquivo baixado do ftp da Bovespa ou podemos usar o comando `ghfd_get_available_tickers_from_ftp` que obtém os *tickers* disponíveis em um mercado e uma data específicos. Os dois comandos apresentam como resultado um vetor numérico com os tickers e outro com o número de transações de cada *ticker*.

```
tickers_equity <- ghfd_get_available_tickers_from_ftp(my.date = "2015-11-03",
  type.market = "equity", max.dl.tries = 10)
```

```
##
## Reading ftp contents for equity (attempt = 1|10) Attempt 1 - File exists, skipping dl
```

```
head(tickers_equity)
```

```
##   tickers n.trades      f.name
## 1  PETR4    52231 ftp files/NEG_20151103.zip
## 2  ITUB4    50437 ftp files/NEG_20151103.zip
## 3  BVMF3    47214 ftp files/NEG_20151103.zip
## 4  VALE5    41959 ftp files/NEG_20151103.zip
## 5  BBDC4    39403 ftp files/NEG_20151103.zip
## 6  ITSA4    37993 ftp files/NEG_20151103.zip
```

Existem 419 *tickers* para o mercado de ações na data especificada.

Para baixar os dados de transações de alta frequência e agregá-los para análise usamos o comando `ghfd_get_HF_data`. Para exemplo usarei os três *tickers* mais comercializados no mercado de ações em 03/11/2015, coletados no período de 30/06/2016 a 30/08/2016.

```
dados_top3 <- ghfd_get_HF_data(c("PETR4", "ITUB4", "BVMF3"), type.market = "equity",
  first.date = as.Date("2016-06-30"), last.date = as.Date("2016-08-30"),
  first.time = "9:00:00", last.time = "18:00:00", type.output = "agg",
  agg.diff = "1 hour", dl.dir = "ftp files", max.dl.tries = 10, clean.files = FALSE)
```

```
load("dados_top3.Rda")
head(dados_top3, n = 3)
```

```
##   InstrumentSymbol SessionDate      TradeDateTime n.trades last.price
## 1              BVMF3 2016-06-30 2016-06-30 10:00:00    2992    17.63
## 2              BVMF3 2016-06-30 2016-06-30 11:00:00    3642    17.67
```

```
## 3          BVMF3  2016-06-30 2016-06-30 12:00:00      2289      17.72
## weighted.price period.ret period.ret.volat sum.qtd  sum.vol n.buys
## 1          17.53706 0.021436848      0.0003225179 1523500 26716617 1238
## 2          17.62966 0.001700680      0.0003044433 1200900 21171287 1395
## 3          17.68812 0.002829655      0.0003512668 1156900 20463311 1079
## n.sells Tradetime
## 1      1754  10:00:00
## 2      2247  11:00:00
## 3      1210  12:00:00
```

```
tail(dados_top3, n = 3)
```

```
##      InstrumentSymbol SessionDate      TradeDateTime n.trades last.price
## 1054          PETR4  2016-08-30 2016-08-30 15:00:00      4943      13.02
## 1055          PETR4  2016-08-30 2016-08-30 16:00:00      5006      13.06
## 1056          PETR4  2016-08-30 2016-08-30 17:00:00       489      13.15
## weighted.price period.ret period.ret.volat sum.qtd  sum.vol n.buys
## 1054          13.02425 -0.003062787      0.0003166287 4252300 55382934 1635
## 1055          13.02341  0.003072197      0.0003043510 5535600 72092146 2506
## 1056          13.09081  0.004583652      0.0003054307 9056300 118554268 184
## n.sells Tradetime
## 1054      3308  15:00:00
## 1055      2500  16:00:00
## 1056       305  17:00:00
```

Por fim o comando `ghfd_read_file` baixa os dados na sua forma bruta, ou seja apenas lê o arquivo .zip baixado do ftp da Bovespa. Nesta opção fica disponível o código da corretora que efetuou a transação.

```
library("GetHFDData")
path <- path.expand("~/artigo_macroecometria_lucca_joao/ftp files/NEG_20160830.zip")
dados_bruto <- ghfd_read_file(out.file = path, my.assets = NULL, first.time = "10:00:00",
                             last.time = "17:00:00", type.output = "raw")
```

```
## - Imported 713224 lines, 475 unique tickers
## -> Processing file - Found 713224 lines, 475 unique tickers
```

```
head(dados_bruto)
```

```
## # A tibble: 6 x 10
##   SessionDate InstrumentSymbol TradePrice TradedQuantity Tradetime
##   <date>         <chr>         <dbl>         <dbl>         <chr>
## 1 2016-08-30      AALC34         32.81           800 16:10:39.669
## 2 2016-08-30      AAPL34         34.50          3600 16:05:22.618
## 3 2016-08-30      AAPL34         34.15          8700 16:10:39.669
## 4 2016-08-30      ABCB10         14.21           500 10:00:57.694
## 5 2016-08-30      ABCB10         14.00          1000 15:01:20.909
## 6 2016-08-30      ABCB10         14.00           400 15:15:49.496
## # ... with 5 more variables: CrossTradeIndicator <int>, BuyMember <dbl>,
## #   SellMember <dbl>, TradeDateTime <time>, TradeSign <dbl>
```

```
tail(dados_bruto)
```

```
## # A tibble: 6 x 10
##   SessionDate InstrumentSymbol TradePrice TradedQuantity Tradetime
##   <date>         <chr>         <dbl>         <dbl>         <chr>
## 1 2016-08-30      XTED11         22.56           30 16:42:14.335
## 2 2016-08-30      XTED11         22.52           85 16:42:14.335
## 3 2016-08-30      XTED11         22.57          500 16:42:14.335
## 4 2016-08-30      XTED11         22.52           3 16:42:14.335
## 5 2016-08-30      XTED11         22.55           6 16:42:14.335
## 6 2016-08-30      XTED11         22.52          172 16:44:59.661
## # ... with 5 more variables: CrossTradeIndicator <int>, BuyMember <dbl>,
## #   SellMember <dbl>, TradeDateTime <time>, TradeSign <dbl>
```

```
head(dados_bruto[, 5:8])
```

```
## # A tibble: 6 x 4
##   Tradetime CrossTradeIndicator BuyMember SellMember
##   <chr>         <int>         <dbl>         <dbl>
## 1 16:10:39.669           0           40           40
## 2 16:05:22.618           1          238          238
## 3 16:10:39.669           0           40           40
## 4 10:00:57.694           0           58          174
## 5 15:01:20.909           0          735          114
## 6 15:15:49.496           0           15          114
```

```
tail(dados_bruto[, 9:10])
```

```
## # A tibble: 6 x 2
##   TradeDateTime TradeSign
##   <time>         <dbl>
## 1 2016-08-30 16:42:14      -1
## 2 2016-08-30 16:42:14      -1
## 3 2016-08-30 16:42:14      -1
## 4 2016-08-30 16:42:14      -1
## 5 2016-08-30 16:42:14      -1
## 6 2016-08-30 16:44:59      -1
```

2 Coletando dados usando quantmod

Dados do mercado financeiro podem ser baixados por um outro pacote chamado **quantmod**. Este pacote baixa os dados de fontes como o Yahoo Finance, Goole Finace e diversas outras fontes (Tsay 2012). A forma que este pacote trabalha á diferente do pacote **GetHFDData**. Com o **quantmod** não é necessário designar objetos, pois este pacote trabalha com objetos ocultos. Segue uma demonstração:

```
library(quantmod)
getSymbols(c("PETR4", "ITUB4", "BVMF3"), src = "google", env = globalenv())
```

```
## [1] "PETR4" "ITUB4" "BVMF3"
```

```
head(PETR4)
```

```
##          PETR4.Open PETR4.High PETR4.Low PETR4.Close PETR4.Volume
## 2007-01-02      25.00      25.22      24.88      25.22      10221200
## 2007-01-03      25.08      25.20      24.00      24.35      19822400
## 2007-01-04      24.25      24.38      23.70      23.82      20910800
## 2007-01-05      23.60      24.00      22.55      23.10      24798200
## 2007-01-08      23.25      23.57      22.90      23.30      19406000
## 2007-01-09      22.98      23.20      22.30      22.76      25847800
```

```
tail(BVMF3)
```

```
##          BVMF3.Open BVMF3.High BVMF3.Low BVMF3.Close BVMF3.Volume
## <NA>      17.80      17.84      17.44      17.49      10652500
## <NA>      17.49      17.62      16.64      17.59      15043000
## <NA>      17.66      17.97      17.60      17.70      12392900
## <NA>      17.69      17.86      17.61      17.80       7893700
## <NA>      17.99      17.99      17.52      17.83      26841900
## <NA>      17.83      18.28      17.75      18.23      10544700
```

```
dim(ITUB4)
```

```
## [1] 2424    5
```

Podemos perceber que os dados fornecidos pelo Google Finance são diários e iniciam em 2007, porém alguns intervalos de datas não estão disponíveis para dados com fonte no Google Finance (provavelmente por conflito de feriados) e os dados para ativos financeiros brasileiros até a data de escrita deste documento só foram encontrados no Google Finance. Realizei o comando `tail` para os demais ativos e estes também não apresentaram as datas mais recentes. Esta base de dados também não fornece o preço ajustado (para ativos financeiros brasileiros) e os dados brutos com discriminação por corretora como na seção anterior. Além disso ao utilizar o pacote `bizdays` que estabelece os dias úteis para o mercado financeiro brasileiro com base no calendário da AMBIMA ainda existe algum conflito entre os dias úteis apresentados pelo Google Finance e pelo `bizdays`. Para mais detalhes sobre o pacote `quantmod` veja Ryan (2016).

3 Organizando a base de dados

A partir de agora utilizarei os dados obtidos usando o pacote `GetHFData` devido ao problema com o pacote `quantmod` relatado anteriormente. a base de dados `dados_top3` contém as informações sobre os três ativos PETR4, ITUB4, BVMF3 no mesmo banco de dados. Portanto temos que separar este banco de dados em três outros arquivos cada um com informações a respeito de apenas um tipo de ação.

Para isso podemos utilizar a função `filter()` do pacote `dplyr`. O banco de dados `dados_top3` possui dimensão (1056, 13).

```
library(dplyr)
PETR4_data <- filter(dados_top3, InstrumentSymbol == "PETR4")
BVMF3_data <- filter(dados_top3, InstrumentSymbol == "BVMF3")
ITUB4_data <- filter(dados_top3, InstrumentSymbol == "ITUB4")
```

Então ele será dividido em três bancos de dados de mesma dimensão (352, 13).

3.1 Plotando os retornos dos ativos

```
library(ggplot2)
library(gridExtra)
plot_PETR4 <- ggplot(PETR4_data, aes(TradeDateTime, period.ret)) +
  geom_line() + scale_x_datetime(date_labels = "%Y-%m-%d %H:%M:%S") +
  xlab("") + ylab("PETR4") + theme(axis.text.x = element_text(size = 7,
    vjust = 0.7, hjust = 0.9))
plot_BVMF3 <- ggplot(BVMF3_data, aes(TradeDateTime, period.ret)) +
  geom_line() + scale_x_datetime(date_labels = "%Y-%m-%d %H:%M:%S") +
  xlab("") + ylab("BVMF3") + theme(axis.text.x = element_text(size = 7,
    vjust = 0.7, hjust = 0.9))
plot_ITUB4 <- ggplot(ITUB4_data, aes(TradeDateTime, period.ret)) +
  geom_line() + scale_x_datetime(date_labels = "%Y-%m-%d %H:%M:%S") +
  xlab("") + ylab("ITUB4") + theme(axis.text.x = element_text(size = 7,
    vjust = 0.7, hjust = 0.9))
grid.arrange(plot_PETR4, plot_BVMF3, plot_ITUB4, name = "Retornos das ações",
  nrow = 3)
```

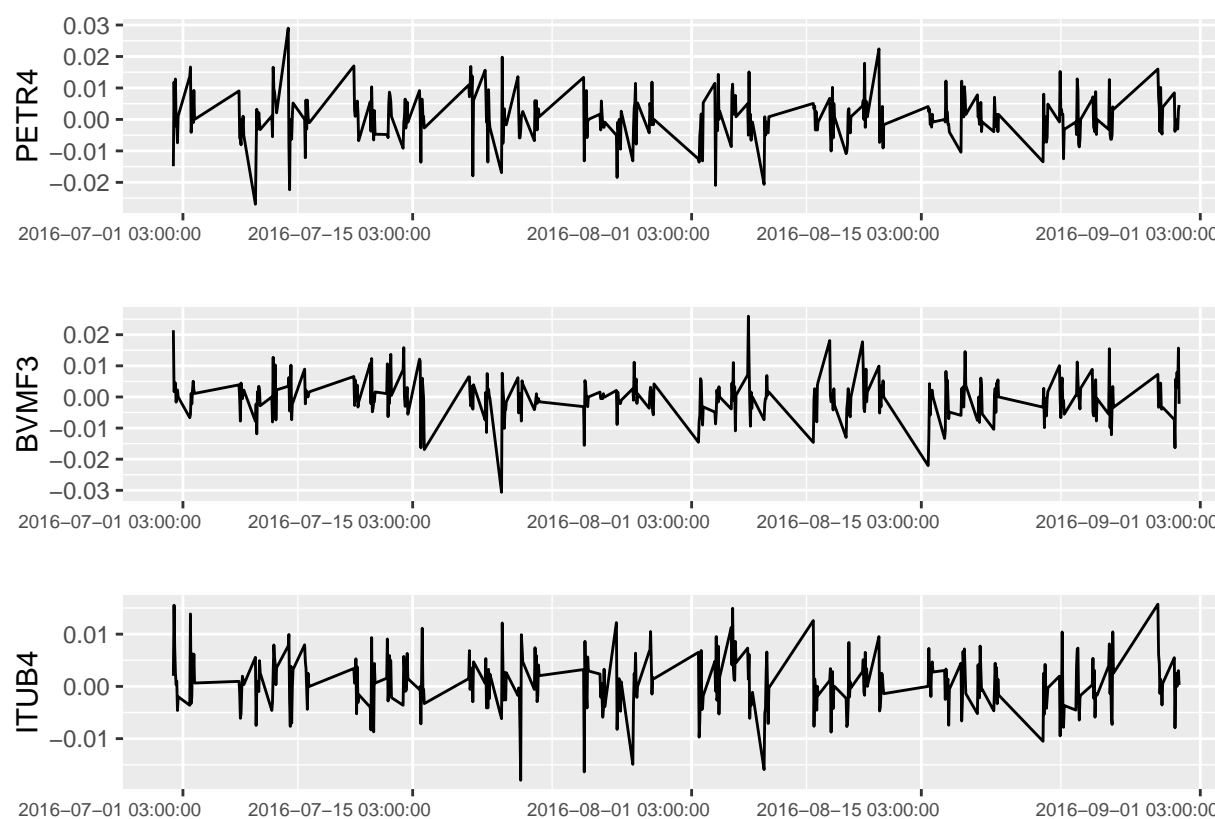


Figura 1: Retornos dos ativos

Visualmente podemos perceber que os retornos oscilam em torno de zero e que esporadicamente ocorrem valores extremos.

4 Propriedades da distribuição dos retornos

Para conhecermos as características da distribuição dos dados usaremos o pacote `fBasics`. Inicialmente são apresentadas algumas estatísticas básicas.

```
library(fBasics)
basicStats(PETR4_data$period.ret)

##                X..PETR4_data.period.ret
## nobs                352.000000
## NAs                  0.000000
## Minimum              -0.026943
## Maximum              0.028986
## 1. Quartile          -0.003815
## 3. Quartile           0.004444
## Mean                 0.000435
## Median               0.000000
## Sum                  0.153196
## SE Mean              0.000388
## LCL Mean             -0.000329
## UCL Mean             0.001199
## Variance             0.000053
## Stdev                0.007287
## Skewness             0.017503
## Kurtosis             1.384462
```

```
basicStats(BVMF3_data$period.ret)

##                X..BVMF3_data.period.ret
## nobs                352.000000
## NAs                  0.000000
## Minimum              -0.030617
## Maximum              0.025946
## 1. Quartile          -0.003256
## 3. Quartile           0.003008
## Mean                 -0.000101
## Median               0.000000
## Sum                  -0.035675
## SE Mean              0.000337
## LCL Mean             -0.000764
## UCL Mean             0.000561
## Variance             0.000040
## Stdev                0.006322
## Skewness             -0.058064
## Kurtosis             2.784860
```

```
basicStats(ITUB4_data$period.ret)

##                X..ITUB4_data.period.ret
## nobs                352.000000
## NAs                  0.000000
## Minimum              -0.017962
```



```
## Maximum          0.015730
## 1. Quartile      -0.002247
## 3. Quartile       0.003588
## Mean             0.000605
## Median           0.000324
## Sum              0.212899
## SE Mean          0.000269
## LCL Mean         0.000076
## UCL Mean         0.001133
## Variance          0.000025
## Stdev            0.005040
## Skewness         -0.064426
## Kurtosis          0.967430
```

Ao realizar as estatísticas básicas, percebi um problema. O cálculo do retorno feito pelo pacote `GetHFDData` é o cálculo de retorno simples, o que torna a soma dos retornos inadequada. Para que a soma dos retornos seja correta, o cálculo do retorno deveria ser em logarítimo, o que possibilita a soma dos retornos. Portanto, para trabalharmos com os retornos dos ativos, devemos calcular o logarítimo do retorno. Conforme Tsay (2012) será utilizado o retorno ponderado pois leva em conta o fracionamento das ações, se ocorridos no período estudado.

Referências

- Perlin, Marcelo. 2016. *GetHFDData: Download and Aggregate High Frequency Trading Data from Bovespa*. <https://CRAN.R-project.org/package=GetHFDData>.
- Perlin, Marcelo, and Henrique Ramos. 2016. “GetHFDData: A R Package for Downloading and Aggregating High Frequency Trading Data from Bovespa.” SSRN Scholarly Paper ID 2824058. Rochester, NY: Social Science Research Network. <https://papers.ssrn.com/abstract=2824058>.
- Ryan, Jeffrey A. 2016. *Quantmod: Quantitative Financial Modelling Framework*. <https://CRAN.R-project.org/package=quantmod>.
- Tsay, Ruey S. 2012. *An Introduction to Analysis of Financial Data with R*. 1 edition. Hoboken, N.J: Wiley.